



Warden Ship: interaktivni vmesnik za raziskovanje umetniških arhivov s semantičnim iskanjem in hkratno klasifikacijo sloga, žanra in avtorja

Matej Breskvar

Univerzitetni študijski program Računalništvo in informatika

Fakulteta za računalništvo in informatiko

Mentor: prof. dr. Narvika Bovcon

Somentor: doc. dr. Blaž Meden

Copyright: To delo je ponujeno pod licenco CC-BY4.0. Razvita programska oprema in rezultati dela so na voljo v okviru GPL-3.0-or-later na <https://github.com/MB37860/Warden-Ship>.

Warden Ship: an interactive interface for exploring art archives with semantic search and multi-task classification

Digitised art collections have outgrown classic metadata search, while the web is being flooded with machine-generated imagery. This work presents *Warden Ship*, an interactive application designed as a keeper of existing, human-made artworks: it points all of its artificial intelligence inward, at exploring the collection. The thesis has two parts: an interactive graphical interface, and a backend of machine-learning models; each is presented and evaluated in its own right. The application renders six equal features – semantic search, style/genre/artist classification, creativity and influence charts, a map of art history, and visual-attribute filters – as scenes of a shared nautical world, connected by a cinematic journey that starts on a 3D ship deck. The frontend is built with React and React Three Fiber; the backend uses Flask with MongoDB and GridFS. The intelligence consists of a CLIP model for text-to-image search, a fine-tuned multi-task vision transformer predicting style, genre and artist, and four classical computer-vision channels for attribute filtering. The models are evaluated on a locally held-out test set of 12,680 images: the fine-tuned ViT-L/336 variant reaches 77.0% accuracy for style (27 classes), 86.3% for genre and 97.3% for artist, whereas the zero-shot CLIP baseline reaches only 25.8%, 57.7% and 56.0%. Three components are then adapted to the art domain or trained anew: contrastive fine-tuning lifts zero-shot CLIP accuracy to 55.3% (style) and 79.8% (genre), an ArcFace metric embedding improves style retrieval from 41.6% to 61.0%, and a new regression head over CLIP embeddings estimates the creation year of a painting with a mean absolute error of 31 years against a naive baseline of 73 years. Test accuracies closely track validation, confirming good generalisation, and the results exceed both the targets of the initial proposal and the source articles.

Semantic image search | CLIP | Multi-task classification | Fine-tuning | Computational art analysis | Interactive visualization

Digitalizirane umetniške zbirke so prerasle zmognosti klasičnega iskanja po metapodatkih, splet pa hkrati preplavlja strojno generirane podobe. V delu predstavimo *Warden Ship*, interaktivno aplikacijo za raziskovanje umetnozgodovinske zbirke s pomočjo umetne inteligence. Diplomsko delo je dvodelno: prvi del je interaktivni grafični vmesnik, drugi pa zaledje z modeli strojnega učenja. Šest enakovrednih funkcionalnosti – semantično iskanje, klasifikacijo sloga, žanra in avtorja, karti ustvarjalnosti in vplivov, zemljevid zgodovine umetnosti ter filtre po vizualnih lastnostih – aplikacija upodobi kot prizore iz skupnega pomorskega sveta, povezane z animiranimi prehodi. Čelni del je izdelan z ogrodjema React in React Three Fiber, zaledje s Flaskom ter zbirko MongoDB z GridFS. Jedro sestavljajo model CLIP za besedilno-slikovno iskanje, doučeni slikovni transformer za hkratno napovedovanje sloga, žanra in avtorja ter štirje kanali klasičnega računalniškega vida za filtriranje po vizualnih lastnostih. Modele ovrednotimo na izločeni testni množici 12.680 slik: doučena različica ViT-L/336 doseže točnost 77,0% pri slogu (27 razredov), 86,3% pri žanru in 97,3% pri avtorju, CLIP brez doučitve pa na istih razredih le 25,8%, 57,7% in 56,0%. Tri komponente nato prilagodimo umetniški domeni oziroma jih na novo naučimo. Kontrastno doučeni CLIP izboljša točnost pri prepoznavanju sloga na 55,3% in žanra na 79,8%, metrična vložitev ArcFace pa poveča natančnost@1 pri slogu z 41,6% na 61,0%. Nova regresijska glava nad vložitvami CLIP letnico nastanka dela oceni s povprečno absolutno napako 31 let v primerjavi z naivno osnovo 73 let. Testne točnosti se tesno ujemajo z validacijskimi, kar potrjuje dobro posploševanje, rezultati pa presegajo zastavljene cilje.

Semantično iskanje slik | CLIP | hkratna klasifikacija | doučitev modelov | računalniška analiza umetnosti | interaktivna vizualizacija

Warden Ship je interaktivna aplikacija za raziskovanje digitaliziranih umetniških zbirk. Njeno temeljno izhodišče je vizualizirano v metaforiki vmesnika: aplikacija je *varuh* (angl. *warden*) obstoječe, človeško ustvarjene umetnosti. Umetno inteligenco usmerja navznoter, v zbirko, da človeku pomaga najti, razumeti in povezati tisto, kar so ustvarili ljudje. Ta drža je vgrajena v celotno uporabniško izkušnjo: uporabnik arhiv *prinese* na krov (naloži datoteko ZIP), ladja ga *hrani*, vsaka funkcionalnost pa je svojevrsten *instrument* za opazovanje zbirke.

Diplomsko delo je dvodelno. Prvi del je *čelni*: interaktivni grafični vmesnik, ki zbirko upodobi kot prostor za krmarjenje in izide modelov pretvori v berljiv podatkovni prikaz. Drugi del je *zaledni*: strežnik z modeli, ki slike obdela, jih vloži v vektorski prostor in klasificira.

Jedro aplikacije je šest enakovrednih funkcionalnosti (F1–F6); vsaka dobi svoj prizor in svoj instrument, povezuje pa jih animirano potovanje po ladji *The Warden*. Oblikovno zasnovano in krmarjenje med prizori opišemo v razdelku 2, posamezne funkcionalnosti v razdelku 4, zaslonke slike vseh prizorov v veliki obliki pa so zbrane v Prilogi A (domači zaslon prikazuje Slika 1). Celotno aplikacijo – prizore, poti zaledja in modele, ki stojijo za posamezno funkcionalnostjo – na enem mestu povzema Slika 11 v Prilogi C. Tehnično jedro aplikacije je povezovalno: raznorodne slikovne modele – CLIP za iskanje, doučene klasifikatorje in vložitve, detektorje klasičnega računalniškega vida – združi v en sam uporabniški tok, v katerem se rezultati vseh modelov stekajo v isti arhiv.

A. Motivacija. Digitalizacija je močno povečala dostopnost umetnin; zbirke, kot je WikiArt [1], obsegajo več deset tisoč del iz različnih obdobij, slogov in žanrov. Klasični arhivski iskalniki se opirajo na naslove, avtorje in oznake, kar zadošča le, kadar uporabnik iskani podatek že pozna. Pri asociativnih, vizualnih vprašanjih – ko nekdo išče dela z motivom nevihtnega morja ali portrete, ne da bi poznal naslove del – tako iskanje odpove. Razmah generativnih modelov hkrati ustvarja poplavo sintetičnih podob; prav v tem kontekstu želi aplikacija poudariti nasprotno držo: ohranjanje in raziskovanje obstoječe človeške umetnosti.

Cilj dela je povezati nalaganje zbirke, obdelavo slik in semantično raziskovanje v enoten, razumljiv uporabniški tok ter ob tem izmeriti zanesljivost modelov, ki aplikacijo poganjajo. Osrednji empirični vprašanja sta, *kako točni so modeli aplikacije na neodvisni*

testni množici in koliko lahko šibkejšo, na fotografijah vnaprej naučene sestavine izboljšamo s prilagoditvijo umetniški domeni.

B. Prispevki. Glavni prispevki dela so:

1. **Delujoča aplikacija kot povezovalni sloj.** Šest funkcionalnosti (F1–F6) združimo v enotno interaktivno izkušnjo s pomorsko metaforiko, v kateri vsak model dobi svoj instrument in prizor.
2. **Celovito ovrednotenje modelov.** Obe učeni različici klasifikatorja F2 ovrednotimo na izločeni testni množici 12.680 slik in ju na istih razredih primerjamo z vnaprej naučenim modelom CLIP brez doučitve (angl. *zero-shot*); točnosti poročamo s 95-odstotnimi Wilsonovimi intervali zaupanja ter jih primerjamo z validacijskimi rezultati učenja in s stanjem tehnike iz referenčnih člankov.
3. **Cevovod učenja in izvoza.** Opišemo pripravo podatkov iz zbirke WikiArt, doučitev z maskirano skupno izgubo na gruči FRIDA ter izvoz samostojnega modela TorchScript, ki ga aplikacija nalaga lokalno.
4. **Prilagoditev dveh modelov umetniški domeni in učenje tretjega.** CLIP kontrastno doučimo na parih slika–opis, naučimo metrično vložitev z izgubo ArcFace [2] ter naučimo regresijsko glavo, ki letnico nastanka dela oceni neposredno iz vložitve CLIP; vse tri modele ovrednotimo na izločenih podatkih in izmerimo prispevek prilagoditve.
5. **Primerjava načrtovanega in izvedenega,** utemeljitev poenostavitve začetnega okvirja ter smernice za nadaljnje delo.

Struktura poglavij: v razdelku 1 delo umestimo med sorodna dela; razdelek 2 opiše zasnovo in čelni del aplikacije, razdelek 3 zaledje, razdelek 4 pa funkcionalnosti F1–F6; v razdelku 5 predstavimo učenje klasifikatorja F2, v razdelku 6 prilagoditev preostalih modelov umetniški domeni, v razdelku 7 pa vse modele ovrednotimo; razdelek 8 primerja načrtovano z izvedenim, razdelek 9 delo sklene.

1. Sorodna dela

Računalniško raziskovanje umetnosti združuje obdelavo slik, strojno učenje, iskanje informacij in interaktivno vizualizacijo. Manovich [3] postavi metodološki okvir – *kulturno analitiko* – v katerem prostor značilk postane hkrati *kulturni prostor*: lega, gručenje in poti v njem so umetnostnozgodovinsko pomenljivi, zmanjševanje dimenzionalnosti pa je orodje za raziskovanje. Castellano in Vessio [4] v preglednem članku popišeta prehod od ročno izdelanih značilk h globokemu učenju ter kot najboljšo prakso izpostavita doučitev na umetniških podatkih in hkratno učenje več nalog (angl. *multi-task learning*).

Klasifikacija in značilke. Saleh in Elgammal [5] sistematično primerjata značilke (GIST, Clasemes, Picodes, CNN) in metode metričnega učenja ter pri slogu (27 razredov) dosežeta 45,97 %; pomembneje, pokažeta, da so *zmote* klasifikatorja umetnostnozgodovinsko smiselne (npr. zamenjave Moneta in Pissarra). Elgammal in sod. [6] analizirajo, kaj se mreže naučijo: že 6–10 glavnih komponent pojasni 95 % variance aktivacij, kotna koordinata v prvih dveh korelira s časom, kar potrjuje gladko evolucijo slogov; njihov najboljši model (ResNet) doseže 63,7 %.

Iskanje in ustvarjalnost. Seguin in sod. [7] so med prvimi uporabili značilke CNN za iskanje vizualno sorodnih motivov po zbirki slik. Saleh in sod. [8] z metričnim učenjem in asimetrično Hausdorffovo razdaljo odkrivajo vplive med slikarji, Elgammal in Saleh [9] pa ustvarjalnost kvantificirata z uteženo različico algoritma PageRank v omrežju implikacij. Stork [10] pregleda širše področje in opozori na izzive, značilke za umetnost (slogovna variabilnost, majhne množice, abstrakcija, motivi brez fizičnega zgleda), ter prispeva analizo drže portretirancev po umetnostnih gibanjih.

Sodobne vložitve in neposredni predhodnik. Model CLIP [11] z učenjem na 400 milijonih parov slika–besedilo ustvari skupni vložitveni prostor slik in besedil, ki omogoča iskanje z naravnim jezikom; DINOv2 [12] ponuja močne samonadzorovane vizualne značilke. Neposredni predhodnik tega dela je prototip Jeniča in sod. [13], ki v šestih ločenih načinih (čustva, objekti, drže, barve, Houghova transformacija in pogled portretiranca) interaktivno pregleduje slikarsko zbirko. Warden Ship te ideje poenoti in nadgradi: doda semantično iskanje s CLIP, doučeni klasifikator ter enotno uporabniško izkušnjo.

2. Zasnova in čelni del

Vmesnik mora zadostiti dvema zahtevama, ki si na prvi pogled nasprotujeta: nositi pomorsko pripoved, ki daje aplikaciji značaj, in hkrati ostati berljiv podatkovni prikaz, saj vsaka funkcionalnost kaže izide modelov. Rešujemo ju z razdelitvijo vmesnika na dve plasti. Vsak prizor je tridimenzionalni prostor, čez katerega je položena tanka

dvodimenzionalna plast z vnosom, stanjem in dejanji: prostor nosi temo, plast nad njim pa podatke. V nadaljevanju opišemo oblikovni jezik obeh plasti, skupno zaslonko masko in krmarjenje med prizori.

Tema in elementi. Pomorski svet ni okras, ampak nosilec pomena: arhiv je tovor, ki ga ladja varuje, vsak model pa dobi svoj instrument za opazovanje tega tovara. Iz tega izhaja osrednje oblikovalsko načelo – *krmilni elementi so predmeti sveta*. V kapitanovi kajuti filtre predstavljajo globus, deska z barvili in lesena lutka, v ladijskem dnevniku so rezultati klasifikacije strani knjige in pergamentne plošče na steni, v *Star Atlasu* pa je vsaka umetnina zvezda, katere sij izraža ujemanje s poizvedbo. Običajen gradnik vmesnika uporabimo le tam, kjer ga predmet ne more nadomestiti – pri besedilnem iskanju in v nastavitvah. Elementi druge plasti so zaobljeni paneli s tanko kovinsko obrobo in polprosojnim temnim polnilom, ovalne značke za stanje ter gumbi z mehkim senčenjem in radialnimi prelivi; polprosojnost ni okrasna, temveč nujna, saj plast leži nad gibljivim prizorom, ki ga ne sme povsem zakriti.

Zaslonska maska. Vsi prizori si delijo isto razporeditev, zato se uporabnik v novem prizoru takoj znajde. Tridimenzionalno platno zavzame ves zaslon, ob njegovih robovih pa so: zgoraj levo vnos in ukazi (iskalno polje s predlogi poizvedb), zgoraj desno značka z imenom prizora in ikono ladijskega kolesa, spodaj levo značke stanja (velikost ozvezdja in najboljše ujemanje pri F1, ime aktivne zbirke v sobi s skrinjo), spodaj na sredini kratek namig za krmarjenje, spodaj desno pa dejanja prizora, na primer nastavitve neba ali odpiranje najboljših zadetkov. Odločitve, ki zahtevajo več pozornosti, prevzame modalno okno, centrirana kartica na zatemnjenem ozadju, kot pri izbiri podatkovne zbirke; napredek dolgotrajnih cevovodov pa oznanja vrstica na vrhu zaslona, ki ostane vidna, medtem ko uporabnik nadaljuje z raziskovanjem.

Tipografija. Pisave so izbrane po vlogi. Naslove, poudarke in napise v svetu nosi *IM Fell English*, digitalizacija angleške pisave iz 17. stoletja; njena zgodovinska risba temo podpre bolj kot katera koli okrasna pisava, a je pri majhnih stopnjah slabše berljiva. Daljša besedila in oznake zato prevzamejo *Palatino Linotype*, *Book Antiqua*, *Palatino* in občasno *Georgia*, goste podatkovne prikaze (števila, odstotki, imena razredov) pa nevtralni niz `system-ui`, `'Segoe UI'`, `Roboto`, `sans-serif`, ki je hkrati rezerva, kadar izbrana pisava ni na voljo. Ena pisava tako daje identiteto, druge pa berljivost.

Barvna paleta. Tudi barve so razporejene po vlogah. Podlago tvorijo globoke modrine morja in noči (`#274766`, `#0c1a29`, `#02070e`) ter skoraj črna lesena notranjost (`#080503`, `#0d0904`); površine z besedilom so pergamentne (`#f5e6c8`, `#d8c59e`, `#ffe9bf`); interaktivni in dejavni elementi so bakreno-zlati (`#d4a017`, `#ffb060`, `#ffd17a`, `#ffb870`), enako kot viri svetlobe v prizorih. Ker plast z besedilom leži nad gibljivim prizorom, ima vsak panel temno polprosojno podlago in svetlo kovinsko obrobo, tako da kontrast ostane zadosten ne glede na dogajanje za njim. Posebno vlogo ima opozorilna barva: z njo označimo podatke, ki jih ni dala zbirka, ampak model – ocenjene letnice na zemljevidu F5 – tako da uporabnik negotovost opazi, še preden prebere pojasnilo.

3D modeli in prostor. Prostorski del je kombinacija pripravljenih in programsko sestavljenih elementov. Iz zbirke Sketchfab so prevzeti štirje modeli `.gltf` – ladja [14], otok [15], teleskop [16] in top [17] –, ki nosijo prizore uvodnega toka; vsi štirje so objavljeni pod licenco CC BY 4.0, avtorji pa so navedeni v literaturi. Preostale prizore – kapitanovo mizo z dnevnikom, kajuto s filtri, ladijski hodnik in kabino s stensko karto – sestavimo programsko s Three.js in React Three Fiber iz osnovnih teles, gradiv in luči, saj se morajo njihovi deli odzivati na podatke: police in strani se polnijo z naloženimi umetninami, ladjice na karti pa se premikajo glede na koordinate zemljevida F5. Osvetlitev povsod izhaja iz vira, ki je v prizoru viden – sveč, svetilke, lune ali zvezd –, zato je svetloba topla in usmerjena, prostor okoli nje pa temen; s tem se pozornost sama zbere na umetnine.

Uvodni tok in dostop. Uvodni tok je linearen – paluba ladje (Slika 1), soba s skrinjo (Slika 2), strel s topom, otok s teleskopom (Slika 3) in *Star Atlas* – ter uporabnika popelje od praznega arhiva do prvega rezultata iskanja. Obvezen ni: ladijski hodnik (Slika 4), v katerega uporabnik vstopi že s palube, je razdelilnik z vrati do funkcionalnosti F2–F6, zato je vsak instrument dosegljiv enako neposredno kot iskanje. Vgrajeni *animirani ogled* (tipka C) celoten tok izvede samodejno, s čimer se projekt lahko predstavlja brez posredovanja, podobno kot predstavitevne strani Googlovih eksperimentov.

Prizori in krmarjenje. Vmesnik je en sam končni avtomat: konstanta `SCENES` v komponenti `App.jsx` našteva enajst stanj, med katerimi so tako pripovedni prizori (paluba, soba s skrinjo, strel s topom, otok s teleskopom, ladijski hodnik) kot vseh šest funkcionalnosti. F1–F6 torej niso ločene strani, temveč enakovredna stanja istega avtomata, kar poenoti prehode in naslavljanje. Vsak prizor je dinamično uvožen z `React.lazy` in izrisan znotraj enega ovoja `Suspense` z nadomestnim prikazom med nalaganjem, zato brskalnik prenese le kodo prizora, v katerem uporabnik dejansko je. Ob zagonu se prebere parameter `?scene=...`, stalno prisotni `SceneNavigator`, izpeljan iz seznama `SCENE_ITEMS`, pa omogoča skok v poljubno stanje. Vloge prizorov povzema

tabela 1, zaslonska slika vsakega pa je v Prilogi A.

Vsak prostorski prizor ima svoj **Canvas** z lastnimi nastavitvami izrisa. Paluba ladje (najzahtevnejši prizor za izris) omeji ločljivost na $dpr=[1, 1.25]$ in izklopi glajenje robov, ladijski hodnik ima bistveno manj geometrije, zato ima ločljivost nastavljeno na $dpr=[1, 1.6]$, vključeno ima tudi glajenje robov, otok s teleskopom pa $dpr=[1, 1.35]$ in sence. Kakovost izrisa je tako uglasena po prizorih, namesto da bi bila enotno znižana na najšibkejšega. Prehod med prizoroma izpelje prekrivna plast, ki sliko zatemni: stanje se zamenja po 900ms, zatemnitev se umakne 500ms zatem, časovniki pa so zbrani v referenci in se ob prekinitvi počistijo, zato prekinjen prehod ne pusti visečega stanja.

Tabela 1. Glavni prizori aplikacije in njihove vloge.

Prizor	Vloga
Paluba ladje	domači zaslon, tridimenzionalna galeja na morju
Soba s skrinjo	izbira baze in nalaganje arhiva (ZIP)
Strel s topom	animiran prehod prek morja
Otok s teleskopom	opazovališče, vstop v iskanje
Star Atlas	semantično iskanje (F1)
Ladijski hodnik	razdelilnik vrat do funkcionalnosti F2–F6

Tehnologije čelnega dela. Uporabniški vmesnik je izdelan z ogrodjem React [18] (funkcijske komponente, leno nalaganje prizorov), gradnjo in razvojni strežnik zagotavlja Vite. Prostorski prizori temeljijo na knjižnici Three.js [19] prek ogrodja React Three Fiber [20] in zbirke pomožnih komponent **drei**. Prehode animira **framer-motion**. Naloženi arhiv ZIP razširi knjižnica JSZip že v brskalniku, slike se nato v paketih pošljejo zaledju, izbrana zbirka pa se ohrani v lokalni shrambi brskalnika, tako da je ob vrnitvi še vedno dejavna. Celotno aplikacijo je mogoče zapakirati v namizno različico z ogrodjem Electron [21], ki ovije zgrajeni čelni del ter upravlja podrejena procesa Flask in vgrajeni MongoDB, tako da končnemu uporabniku ni treba namestiti ničesar.

Ključno načelo zasnove: vse modele izvaja zaledje, čelni del pa je tanek, a bogat odjemalec, ki prek klicev REST (**imageApi**, **f2Api**, **f5Api**, **f6Api** ...) bere vnaprej izračunane rezultate. Računsko zahtevno delo se opravi vnaprej v ozadju, vmesnik pa ostane odziven.

3. Zaledni del

Zaledje je ena sama storitev Flask [22], ki registrira šest sklopov poti (angl. *blueprints*) – med njimi izvajalnik cevovodov (angl. *pipelines*) v ozadju – ter ima v lasti vse napovedovanje modelov in vso trajno hrambo. Čelni del komunicira z bazo in modeli izključno prek vmesnika REST.

Podatkovni sloj. Shramba je večzbirovna: vsaka uporabniško imenovana zbirka postane samostojna baza MongoDB. Znotraj nje GridFS [23] hrani surove bajte slik, zbirka **image_metadata** pa po en dokument na sliko: identifikator datoteke, ime, velikost, oznake, neobvezno vložitev CLIP (normirano na enotsko dolžino) in objekt **features** z rezultati cevovodov (npr. **features.f2**). Ločitev binarnih podatkov od poizvedljivih metapodatkov in vektorja je preprosta in robustna za obravnavane velikosti arhivov (od 10 do več kot 1000 slik).

Storitev CLIP. Modul **clip_service.py** je leno ustvarjen edinec (angl. *singleton*) okoli modela **openai/clip-vit-base-patch32** iz knjižnice Transformers [24]: slike in besedila pretvarja v normirane vektorje, zato je kosinusna podobnost kar notranji produkt. Sistem je zasnovan tako, da ob izpadu modela deluje naprej v okrnjeni obliki: če CLIP ni na voljo, nalaganje slik vseeno uspe (brez vložitve), zaledje ohrani leksikalni rezervni način, čelni del pa prikaže sporočilo o nedosegljivosti modela in iskanje onemogoči.

Izvajalnik cevovodov. Modul **pipeline_api.py** vsak zahtevani cevovod požene v delovni niti in spremlja njegovo stanje ter napredek; stanje je zapisano v datoteko z zaklepanjem, zato preživi ponovni zagon, vmesnik pa ga spremlja s poizvedbami vsakih 1,5s. Cevovod **F1** sproti izračuna in shrani vložitve CLIP; **F2** klasificira slike in rezultat zapiše nazaj v metapodatke; **F5** in **F6** se zažene kot ločena procesa, ki zapišeta artefakte JSON, vezane na posamezno bazo. Iskalna pot **/semantic-search** izračuna vložitev poizvedbe, iz baze naloži slikovne vložitve, jih za kratek čas predpomni kot matriko NumPy in rezultate razvrsti po kosinusni podobnosti; linearni pregled s časovno zahtevnostjo $O(N \cdot d)$ za te velikosti zadošča. Skripte za gradnjo indeksa FAISS [25] so pripravljene za prihodnjo nadgradnjo na bistveno večje zbirke.

4. Funkcionalnosti F1–F6

Vsaka funkcionalnost spremeni eno raziskovalno idejo iz literature v interaktiven prizor. Katera inteligenca stoji za katero funkcionalnostjo, pregledno prikazuje Slika 11 v

Prilogi C: prizor, pot REST in modeli so zloženi v isti stolpec, z zvezdico pa so označeni modeli, ki smo jih v tem delu naučili sami ali prilagodili umetniški domeni (razdelka 5 in 6). Notranjo zgradbo teh modelov prikazuje Slika 12 v isti prilogi. Tabela 2 strne, kaj posamezna funkcionalnost počne in kateri modeli jo poganjajo; odstavki za njo vsako opišejo podrobneje.

Tabela 2. Funkcionalnosti F1–F6: naloga posamezne funkcionalnosti in modeli, ki jo poganjajo. Z zvezdico so označeni modeli, ki smo jih v tem delu naučili sami ali prilagodili umetniški domeni (razdelka 5 in 6).

Funkcionalnost	Kaj dela	Modeli in metode
F1 – Star Atlas	Poizvedba v naravnem jeziku; zbirka se preuredi v ozvezdje, v katerem oddaljenost od središča pomeni pomensko oddaljenost od poizvedbe.	CLIP*, kosinusna podobnost nad predizračunanimi vložitvami
F2 – Logbook	Slikam, naloženim brez pravega imena, napove slog (27 razredov), žanr (10) in avtorja (25) s stopnjami zaupanja.	ViT-L/14 CLIP s tremi izhodnimi glavami*, hkratno učenje z maskirano izgubo
F3 – ustvarjalnost	Vsako delo na pomorski karti oceni po izvirnosti in odmevu v poznejših delih ter pokaže trend skozi čas.	Brez lastnega modela; izpeljano na odjemalcu iz koordinat F5
F4 – vplivi	Na isti karti izriše časovno usmerjene povezave med vizualno sorodnimi deli.	Brez lastnega modela; izpeljano na odjemalcu iz koordinat F5
F5 – Chart Table	Zemljevid zgodovine umetnosti: zbirko projicira v ravnino in jo razporedi po času nastanka.	Metrična vložitev ArcFace* oziroma vložitev CLIP, združena z vizualnimi deskriptorji; PCA, gručenje; regresijska glava za oceno letnice*
F6 – Captain's Quarters	Štirje filtri po vizualnih lastnostih, izračunani vnaprej, ki se poljubno sestavljajo.	MediaPipe (drža rok); RetinaFace in geometrija obraznih točk (drža portretiranja); Houghova transformacija (OpenCV); HSL in k -means (barve); metapodatki WikiArt (poreklo)

F1 – Star Atlas (semantično iskanje). Uporabnik vpiše poizvedbo v naravnem jeziku (npr. *a stormy sea at night*), zbirka pa se preoblikuje v ozvezdje okrog osrednje besede poizvedbe (Slika 5). Besedilo vloži CLIP [11], shranjene slikovne vložitve pa se ocenijo s kosinusno podobnostjo. Oddaljenost zvezde od središča je edina pomenonosna prostorska spremenljivka: določa jo *rang* umetnine znotraj rezultata, ne surova podobnost – kosinusne podobnosti CLIP namreč zasedajo ozek absolutni pas (razpon celotnega rezultata je tipično okrog 0,06), zato bi neposredna preslikava vse zvezde postavila na skoraj enako oddaljenost. Najboljši zadetek sedi tik ob besedi, najšibkejši na obodu, velikost in sij zvezde pa sledita istemu rangi; kot okrog središča ne nosi pomena (zaporedni rangi so razmaknjeni za zlati kot, da se krog enakomerno zapolni). Uporabnik izbere le barvno temo neba; lebdenje nad zvezdo pokaže predogled umetnine, klik jo odpre v celozaslonskem pogledu. Med izračunom se prejšnji zemljevid umakne animaciji gradnje, tako da uporabnik nikoli ne vidi zastarelih rezultatov.

F2 – Logbook (klasifikator). Za vsako sliko s pomanjkljivimi podatki napove slog (27 razredov), žanr (10) in avtorja (izmed 25 najbolj zastopanih v zbirki WikiArt) s stopnjami zaupanja. Prizor je kapitanova miza z odprtim dnevnikom (Slika 6): štiri umetnine naenkrat, po dve na vsaki strani. Listamo s puščicami, tipkovnico ali potegom, klik na umetnino pa sproži izpis napovedi na treh pergamentnih ploščah na steni kabine. V ozadju teče doučeni slikovni transformer s tremi izhodnimi glavami (razdelek 5); vsi trije sezname razredov so v Prilogi B.

F3 in F4 – ustvarjalnost in vplivi. Obe funkcionalnosti se izpeljeta na strani odjemalca iz koordinat zemljevida F5 (x, y , leto) in si delita prizor – stensko pomorsko karto, na kateri vsaka umetnina nastopi kot ladjica. V načinu ustvarjalnosti višina in sij ladjice izražata oceno ustvarjalnosti (uteženo vsoto izvirnosti in odmeva v poznejših delih), svetlobna črta pa njen trend skozi čas; v načinu vplivov karta izriše časovno usmerjene povezave med vizualno sorodnimi deli, klik na ladjico ohrani samo njeno pot, ponovni klik pa odpre umetnino (Sliki 7 in 8). Gre za lahkotna, interaktivna približka idej iz [9] in [8]; polni izračun obeh omrežij ostaja nadaljnje delo.

F5 – Chart Table (zemljevid zgodovine). Cevovod vsako delo opiše z dvema vrstama značilk: z nevronske vložitvijo (metrična vložitev ArcFace, sicer CLIP) in z naborom preprostih vizualnih deskriptorjev, izračunanih neposredno iz slike. Standardizirana vektorja združi z utežema 0,85 in 0,35 – kadar nevronske vložitve ni, karto nosijo sami deskriptorji – nato pa izvede projekcijo PCA, gručenje in povezovanje najbližjih sosedov ter zapiše koordinate – interaktivna izvedba ideje o »obliki umetnostne zgodovine« [6], umeščena v okvir kulturne analitike [3]. Letnico posameznega dela razreši veriga virov:

metapodatki, letnica v imenu datoteke, zapis WikiArt ali življenjska doba avtorja; kadar vsi odpovedo, letnico iz vložitve CLIP napove naučena regresijska glava (razdelek 6). Kadar tudi ta ni na voljo, delo ostane *nedatirano* in ga časovnica prikaže v ločenem pasu – cevovod letnice nikoli ne izumi iz položaja v projekciji, ker položaj v slogovnem prostoru ni dokaz o času nastanka. Vsako ocenjeno letnico vmesnik na karti in v časovnici označi z opozorilno barvo ter pojasnilom (Slika 9).

F6 – Captain’s Quarters (filtri po lastnostih). Štirje kanali klasičnega računalniškega vida, vsi izračunani vnaprej: drža rok (MediaPipe [26]), barve (HSL in razvrščanje k-means), Houghova transformacija (OpenCV) ter drža portretiranca (RetinaFace in geometrija petih obraznih točk); metapodatki WikiArt dodajo še filter porekla, ki narodnost avtorja preslika v celino. Ujemanje je pri kanalih z absolutnim pomenom (odtenek, smer pogleda, drža rok) absolutno, pri količinah, ki kažejo razliko predvsem znotraj zbirke (nasičenost in svetlost barve, gostota in smer črt), pa *rangirano znotraj naložene zbirke*, tako da vsak pas zajame njeno tretjino; kadar kanal lastnosti ne more izmeriti dovolj zanesljivo – obraz, premajhen, da bi bil predmet slike, sklep, ki ga model ni videl, ali sivinska slika brez odtenka – delo raje ostane brez oznake, kot da bi dobilo izmišljeno. Barvni kanal delo uvrsti pod *vsako* od šestih barvnih družin, ki so mu pripisane, in ne le pod prevladujočo barvno družino. Izbrana barvila se združujejo s konjunkcijo, zato vsako dodatno barvilo zoži izbor (na testni zbirki modra vrne 40 od 100 del, kombinacija modre in rumene pa 20). Pasova nasičenosti in svetlosti pripeto barvilo le natančneje opredelita, sama zase pa ne izvajata filtriranja. Štirje kanali imajo v kajuti svoj predmet: desko z barvili, desko z vrvicami, leseno lutko in izrezljano glavo. Globus dodaja podatek o poreklu (razdelek 2). Nastavitve se poljubno sestavljajo, možnost brez zadetkov v naloženi zbirki pa so zatemnjene in opremljene s prikazanim številom. Ujemajoče se umetnine se sproti izrisujejo v pladnju ob dnu zaslona (Slika 10). Ker so vsi kanali izračunani vnaprej, je prikaz takojšen. Razrede vseh kanalov navaja Priloga B. Funkcionalnost povzame prototipne načine iz [13] in jih poenoti v en sam prizor.

5. Hkratno učenje klasifikatorja F2

Večina inteligence v aplikaciji je vnaprej naučena (CLIP za F1 in F5; RetinaFace in MediaPipe za F6). Prvi in osrednji model, ki ga učimo sami, je klasifikator F2, ki se hkrati uči treh nalog (angl. *multi-task*); prilagoditev preostalih sestavin in učenje ocenjevalnika letnice opišemo v razdelku 6.

Arhitektura. Osnovna mreža (angl. *backbone*) je slikovni transformer [27] z utežmi CLIP iz knjižnice `timm` [28], na katero so pripete tri linearne izhodne glave (angl. *heads*) za slog, žanr in avtorja; shemo prikazuje Slika 12a v Prilogi C, seznami razredov pa so v Prilogi B. Učimo z *maskirano skupno izgubo*, saj smo se pri napovedi avtorja omejili na 25 avtorjev z največ deli v zbirki WikiArt (večina avtorjev ima v zbirki premalo del, da bi se model lahko prilagodil na razlike). To pomeni, da vsak primer posodobi samo glave, za katere ima oznako. Uporabimo uteži razredov, glajenje oznak, mešanje učnih primerov (angl. *mixup*) in naključno bogatenje učnih podatkov (RandAugment).

Postopek. Skripta `prepare_dataset.py` pregleda arhive WikiArt, zgradi učno in validacijsko množico ter *testno množico izloči in hrani na lokalnem računalniku*, tako da gruča nikoli ne vidi. Učenje teče na gruči FRIDA (SLURM, GPE) s skripto `train_f2.py` (PyTorch [29]); najboljša kontrolna točka se ob vsaki izboljšavi validacijske točnosti znova izvozi kot samostojen model TorchScript z vgrajeno normalizacijo. Aplikacija ta artefakt naloži lokalno (privzeto na CPE) in ima robustno verigo rezerv: izvoženi model → CLIP brez doučitve → determinističen naključni odgovor, zato klasifikacija nikoli ne odpove v celoti. Učeni sta dve različici (tabela 3).

Tabela 3. Učeni različici klasifikatorja F2.

	Osnovna	Visokoločljivostna
Osnovna mreža	ViT-B/16 CLIP	ViT-L/14 CLIP
Vhod	224 × 224	336 × 336
Artefakt	344 MB	1,2 GB
Učenje	15 epoh	50 epoh (najboljša pri 46)

6. Prilagoditev modelov umetniški domeni

Preostala inteligenca aplikacije izvira iz modelov, vnaprej naučenih na fotografijah, ki na stiliziranih podobah izgubljajo zanesljivost [10]; CLIP brez doučitve se poleg tega pri klasifikaciji sloga, žanra in avtorja izkaže za občutno prešibkega (razdelek 7). Umetniški domeni zato prilagodimo dva modela (ArcFace, CLIP), kot tretjega pa na novo naučimo regresijsko glavo za oceno letnice nastanka. Cevovodi znova uporabijo obstoječo

infrastrukturo, to je učno zbirko F2. Prva dva tečeta na gruči FRIDA (SLURM, ena GPE A100), vsak model pa se izvozi v obliki, ki jo aplikacija neposredno naloži. Zgradbo vseh treh prikazujejo plošče (b)–(d) Slike 12 v Prilogi C.

Metrična vložitev (ArcFace). Zemljevid F5 dela razporeja in gruči po legi v vložitvenem prostoru splošnega modela CLIP, ki pa ni prilagojen temu, da bi dela *istega sloga* ležala skupaj. Zato naučimo namensko metrično vložitev: na osnovno mrežo ViT-B/16 z utežmi CLIP pripnemo linearno projekcijo v 512-razsežni prostor z normo ena, učimo pa z izgubo ArcFace [2], ki kosinusnim logitom pravičnega razreda (nadzor je slog) prišteje kotni pribitek $m = 0,3$ pri skali $s = 30$. Naivna izvedba z inverznim kosinusom se izkaže za numerično nestabilno: gradient funkcije $\arccos$ raste čez vse meje, ko se kosinusna podobnost pravilno razvrščenih primerov približuje ena – torej natanko takrat, ko se model začne uspešno učiti – zato je učenje v drugi epohi divergiralo. Glavo zato zapišemo z adicijskim izrekom $\cos(\theta + m) = \cos \theta \cos m - \sin \theta \sin m$, kar $\arccos$ v celoti odpravi in učenje stabilizira: v dvajsetih epohah izguba gladko pade z 8,35 na 0,23. Izvoženi model je, tako kot pri F2, samostojen TorchScript z vgrajeno normalizacijo; cevovod F5 ga samodejno uporabi za izračun vložitev.

Kontrastna doučitev modela CLIP. Besedilno iskanje F1 je odvisno od tega, kako dobro sta usklajena besedilni in slikovni kodirnik na umetnostnem besedišču. Iz metapodatkov učne zbirke F2 (slog, žanr, avtor) za vsako sliko sestavimo naravnojezikovni opis in oba kodirnika doučimo s simetrično izgubo InfoNCE na parih slika–opis, enako kot pri izvornem učenju modela CLIP [11], a z majhno stopnjo učenja ($3 \cdot 10^{-6}$, deset epoh, paketi po 256). Najboljša kontrolna točka se izbere po povprečni točnosti brez doučitve pri slogu in žanru na validacijski množici ter izvozi kot standardni imenik knjižnice Transformers; `clip_service` jo ob prisotnosti samodejno izbere namesto osnovnega modela, zato doučeni CLIP iskanje poganja kot privzeti.

Ocena letnice nastanka (regresijska glava nad CLIP). Zemljevid F5 letnico dela potrebuje za časovnico in usmeritev projekcije. Veriga metapodatkovnih virov pri neoznačenih arhivih pogosto odpove. Prvotna rezerva je bila linearna regresija iz koordinat PCA znotraj naloženega arhiva. Delovala je le, kadar je arhiv že vseboval dovolj del z znano letnico. Zato naučimo samostojno glavo, ki letnico napove neposredno iz vložitve CLIP. Gre za večplastni perceptron s 512 skritimi enotami, aktivacijsko funkcijo GELU in stopnjo izpusta 0,15. Nad L2 normirano vložitvijo napove porazdelitev čez 73 desetletnih razredov med letoma 1300 in 2029. Končna napoved je pričakovana vrednost glede na središča razredov, največja verjetnost razreda pa služi kot mera zaupanja. Učimo s križno entropijo proti Gaussovo zglaženim mehkim ciljem ($\sigma = 1,5$ razreda, približno 15 let), s čimer se naloga vede kot ordinalna regresija; primere utežimo z inverznim korenom pogostosti desetletja, ker je zbirka WikiArt močno nagnjena k obdobju 1800–2000. Podatke sestavlja 137.646 slik WikiArt z znano letnico, razdelitev 80/10/10 pa je *ločena po avtorjih* (slikar iz testne množice se v učni nikoli ne pojavi), kar je konservativna ocena za neznane arhive. Glava porabi natanko tiste vektorje, ki jih zaledje že računa, zato učenje poteka brez dekodiranja slik; izvožena je kot samostojen TorchScript z vgrajeno normalizacijo, cevovod F5 pa jo uporabi za vse slike brez razrešene letnice in vir označi kot `model_estimate`.

7. Eksperimenti in rezultati

Cilj eksperimentov je dvojen: neodvisno izmeriti točnost modelov na izločeni testni množici ter kvantificirati prispevek prilagoditve umetniški domeni iz razdelka 6. Najprej ovrednotimo tri modele klasifikacije: obe učeni različici F2 in vnaprej naučeni CLIP brez doučitve kot izhodišče; vsi trije uporabljajo iste razrede (27 slogov, 10 žanrov, 25 avtorjev) in isto testno množico, zato so rezultati neposredno primerljivi. Nato po istih protokolih izmerimo še prilagojene modele.

7.1. Eksperimentalno okolje in metoda. Vsa ovrednotenja tečejo na lokalnem računalniku, izključno na CPE (PyTorch 2.12, brez CUDA). Testno množico sestavlja 12.680 izločenih slik v polni ločljivosti, ki jih gruča med učenjem ni videla. Oznake so po glavah redke, zato vsako glavo ocenimo le na slikah z ustreznim oznako: slog $n = 9666$, žanr $n = 10\,319$, avtor $n = 1392$.

Učena modela F2. Ocenjevalna skripta `evaluate_local.py` natančno ponovi preddobdelavo iz učenja (skaliranje krajše stranice, sredinski izrez; normalizacijo model opravi sam), izračuna točnost po glavah s 95-odstotnimi Wilsonovimi intervali zaupanja in zapiše strojno berljivo poročilo JSON. Ker model ViT-L/336 na CPE obdela približno pol slike na sekundo, celoten prehod traja 7,2 ure; oba modela sta vseeno ovrednotena na celotni testni množici, zato intervali zaupanja odražajo le velikost množice in ne vzorčne napake.

CLIP brez doučitve. Vnaprej naučeni `clip-vit-base-patch32` – isti model, ki v aplikaciji poganja iskanje F1 in zemljevid F5 – ovrednotimo brez vsakršnega učenja na celotni testni množici. Imena razredov pretvorimo v besedilne pozive (npr. *a painting in the Baroque style, a landscape painting, a painting by Camille Pissarro*), jih vložimo z

besedilnim kodirnikom in vsako sliko uvrstimo v razred z najvišjo kosinusno podobnostjo. Vsaka slika je vložena samo enkrat in ocenjena na vseh treh glavah; celoten prehod na CPE traja 962s (13,2 slike/s).

Prilagojeni modeli. Doučeni CLIP ovrednotimo z natanko istim protokolom brez doučitve na naključnem vzorcu 2000 testnih slik (seme 42). Vložitvi – izhodiščno CLIP in naučeno ArcFace – primerjamo z iskanjem najbližjih sosedov na istem vzorcu: vsaka slika poizveduje po preostalih 1999, merimo pa delež poizvedb, pri katerih ima najbližji sosed isti slog (natančnost@1), in delež sosedov istega sloga med najbližjimi desetimi (natančnost@10). Glavo za oceno letnice ovrednotimo na njenem testnem delu, ločenem po avtorjih (12.239 slik), z merama povprečne in mediane absolutne napake ter deležem napovedi znotraj ± 50 let; kot osnovo vzamemo naivno napoved, ki vsem slikam pripiše mediano letnic učne množice.

7.2. Rezultati. Tabela 4 povzema izmerjene točnosti ob validacijskih iz učenja. Visokoločljivostni model je najboljši pri vseh treh glavah: **slog 0,770** (9 odstotnih točk nad osnovnim modelom), **žanr 0,863** in **avtor 0,973**.

Tabela 4. Točnost na izločeni testni množici 12.680 slik: CLIP brez doučitve (BD) ter validacijska (val) in testna (test) točnost obeh učenih modelov F2. Vsi trije modeli so ovrednoteni na celotni množici.

Glava	CLIP	ViT-B/224		ViT-L/336	
	BD	val	test	val	test
Slog (27)	0,258	0,667	0,681	0,759	0,770
Žanr (10)	0,577	0,842	0,837	0,873	0,863
Avtor (25)	0,560	0,938	0,945	0,972	0,973
Povprečje	0,465	0,816	0,821	0,868	0,868

Wilsonovi intervali zaupanja (iz poročil JSON): pri osnovnem modelu slog [0,671; 0,690], žanr [0,830; 0,844], avtor [0,931; 0,956]; pri visokoločljivostnem slog [0,761; 0,778], žanr [0,856; 0,869], avtor [0,963; 0,980]; pri CLIP brez doučitve slog [0,249; 0,267], žanr [0,567; 0,586], avtor [0,534; 0,586]. Čas na CPE: osnovni model 2565s za celotno množico, visokoločljivostni 25.850s (7,2 h) za isto množico.

Prispevek doučitve. Razlika med modelom brez doučitve in doučenim modelom ViT-L/336 znaša +51,2 odstotne točke pri slogu ($0,258 \rightarrow 0,770$), +28,6 pri žanru in +41,2 pri avtorju. CLIP brez doučitve je torej za neposredno klasifikacijo umetnostnozgodovinskih kategorij občutno prešibek, kar potrjuje, da je bilo lastno učenje klasičnikarja F2 potrebno.

Ujemanje testne in validacijske točnosti. Izmerjena testna točnost se skoraj natančno ujema z validacijsko; pri najtežji glavi (slog) jo pri obeh modelih celo preseže (+1,3 oz. +1,1 odstotne točke). To je značilen podpis modela, ki se **dobro posplošuje** – prekomernega prileganja ni. Ujemanje je najtesnejše pri glavi avtorja visokoločljivostnega modela (0,972 proti 0,973), povprečji obeh modelov pa se ujemata na tretjo decimalno.

Analiza po razredih. Poleg skupne točnosti glave avtorja iz tabele 4 poročili JSON hranita tudi točnost vsakega razreda posebej. Ker so oznake redke, je vsak avtor ovrednoten na svojem številu testnih slik; to število označimo z n . Točnost 1,00 pomeni, da je model pravilno pripisal vseh n slik tega avtorja, pri majhnem n pa je taka vrednost slabo podprta – razred s tremi slikami doseže 1,00 že s tremi zaporednimi pravilnimi napovedmi.

Visokoločljivostni model, ovrednoten na vseh 1392 testnih slikah z oznako avtorja, se po razredih giblje med 0,91 in 1,00; nobeden od 25 avtorjev ne odpove, sedem pa jih model razpozna brez ene same napake (med njimi Piranesi pri $n = 107$ in Steinlen pri $n = 84$). Najnižje uvrščena sta Camille Pissarro (0,91, $n = 74$) in Paul Cézanne (0,91, $n = 44$). Vseh 38 napak glave avtorja smo razporedili v matriko zmot. Največja celica je Boris Kustodijev $\rightarrow$ Ilja Repin (3), sledita Pissarro $\rightarrow$ John Singer Sargent (2) in Pissarro $\rightarrow$ Paul Gauguin (2). Cézannove napake se porazdelijo med Pissarroja, Gauguina, Matissa in Sargentata. Napake se torej zbirajo v povezani skupini slikarjev, ki so se med seboj poznali. Repin je bil Kustodijev učitelj, Pissarro je mentoriral Gauguina, Cézanne pa je delal ob Pissarroju v Pontoiseu. To se ujema z ugotovitvijo Saleha in Elgammala [5], da zmote klasičnikarjev umetnin sledijo umetnostnozgodovinski sorodnosti razredov. Ker je napak le 38 in največja celica šteje tri primere, gre za opaženo smer in ne statistično močan dokaz. Omejitev na 25 najpogostejših avtorjev tako opravlja svojo nalogo: razreda, ki bi zaradi premalo učnih primerov točnost potegnili navzdol, v naboru ni.

7.3. Rezultati prilagoditve domeni. Tabela 5 beremo po vrsticah kot »pred in po« prilagoditvi. Kontrastna doučitev dvigne točnost pri slogu z 0,258 na **0,553** in pri žanru z 0,577 na **0,798** – doučeni CLIP torej brez dodatnega učenja glav po umetnostnem besedišču razvršča več kot dvakrat bolje. Metrična vložitev ArcFace izboljša natančnost@1

pri slogu z 0,416 na **0,610** in natančnost@10 z 0,329 na **0,608**; ker natančnost@10 meri *vseh* deset sosedov hkrati, njen dvig pomeni, da je slogovno sosedstvo v novem prostoru gostejše in enotnejše, kar neposredno koristi gručenju in povezovanju sosedov na zemljevidu F5. Ker ArcFace nima besedilnega kodirnika, besedilnega iskanja F1 ne more poganjati; to ostaja naloga doučenega modela CLIP. Testni vrednosti se ujemata z validacijskima iz učenja (0,610 in 0,599), torej se tudi ta model dobro posplošuje. Glava za oceno letnice na testni množici z ločenimi avtorji doseže povprečno absolutno napako **31,2** leta in mediano 18,8 leta; 85,1 % napovedi je znotraj ± 50 let. Naivna osnova zgreši v povprečju za 73,5 leta, glava pa napako več kot prepolovi. Napaka je najmanjša v podatkovno bogatem 19. in 20. stoletju (26–28 let), pri delih iz 15.–17. stoletja pa naraste na 45–62 let.

Tabela 5. Prispevek prilagoditve umetniški domeni: mere pred prilagoditvijo in po njej. Točnost doučenega modela CLIP (izmerjena po istem protokolu kot pri modelu brez doučitve) in natančnost@ k sta merjeni na naključnem vzorcu 2000 izločenih testnih slik, glava za letnico na testnem delu zbirke WikiArt, ločenem po avtorjih (12.239 slik), kjer je »pred« naivna napoved mediane učne množice in je nižja vrednost boljša.

Model	Mera	Pred	Po
CLIP (brez doučitve)	točnost, slog (27)	0,258	0,553
CLIP (brez doučitve)	točnost, žanr (10)	0,577	0,798
Vložitev	natančnost@1, slog	0,416	0,610
Vložitev	natančnost@10, slog	0,329	0,608
Letnica (glava)	MAE (leta)	73,5	31,2
Letnica (glava)	mediana napake (leta)	–	18,8

7.4. Zamrznjeni modeli brez referenčnih oznak. Detektorja telesnih drž in obrazov (MediaPipe, RetinaFace) ostajata zamrznjeni komponenti, vnaprej naučeni na fotografijah; njuna zanesljivost na stiliziranih podobah je znano šibkejša [10]. Za držo portretiranca smo pokritost in smer izmerili sami: na 46 figuralnih slikah testne množice FaceMesh najde 14 obrazov (30 %) z geometrijsko nemogočimi koti ($\pm 180^\circ$), RetinaFace pa 35 (76 %) s koti v verjetnem razponu $-55^\circ \dots +63^\circ$; vizualni pregled vseh zadetkov pokaže okrog 89 % pravih smeri, pri čemer so vse napake za en sektor ob meji, brez zamenjav levo–desno. Aplikacija izhode teh detektorjev obravnava kot raziskovalne filtre: raje kot da bi ugibala, delo pusti brez oznake. Napake blaži s pragovi (okostje ≥ 8 % površine slike; samostojen obraz $\geq 0,5$ % oziroma na množičnih prizorih ≥ 1 % površine slike; sklep okostja z vidnostjo $\geq 0,5$; nasičenost $\geq 0,12$ za dodelitev odtenska; delež platna ≥ 12 % za uvrstitev dela pod barvno družino; smer črt nad deležem 1/3), z vnaprejšnjim izračunom in s prečiščenimi, agregiranimi prikazi. Cena te strogosti je pokritost: držo portretiranca dobi 29, držo rok pa 14 od 100 slik testne zbirke – preostale nimajo zaznavnega obraza oziroma zapestja.

7.5. Presoja. Klasifikator F2 ne potrebuje dodatnega učenja. Oba učena modela F2 sta zdrava, dobro posplošena in presegata tako cilje predloga kot izvirne članke: pri slogu izvirna dela poročata 45,97 % [5] oz. 63,7 % [6], tu pa dosežemo 68 % (osnovni) oziroma **77 %** (visokoločljivostni model). Priporočilo: model ViT-L/336 ostane privzeti (najboljši pri vseh treh glavah), ViT-B/224 pa približno desetkrat hitrejša rezerva za računalnike brez GPE.

Prilagoditev domeni se je obrestovala povsod, kjer smo jo izvedli. Nizek rezultat CLIP brez doučitve je natančno izmeril, koliko znanja o umetnostnih kategorijah splošnemu modelu manjka; kontrastna doučitev je ta primanjkljaj v veliki meri odpravila, metrična vložitev pa je prostor podobnosti slogovno uredila. Naučena glava za letnico je heuristično oceno na zemljevidu F5 nadomestila z napovedjo, ki napako naivne osnove več kot prepolovi in je prvič tudi izmerjena. Vsi prilagojeni modeli so v razvojni namestitvi že privzeti: zaledje jih ob prisotnosti samodejno naloži namesto izhodiščnih.

8. Razprava: načrtovano in izvedeno

Začetni predlog je bil širok sintezni načrt enajstih člankov, ki smo jih predstavili v razdelku 1; izdelek je osredotočena, delujoča podmnožica. Nekateri deli so uresničeni v celoti (F2), drugi poenostavljeni: F3 in F4 sta interaktivna približka namesto polnih omrežij, F5 uporablja CLIP in PCA namesto celotne analize aktivacijskega prostora z Wölfliinovimi osmi, F6 pa ne implementira vseh zastavljenih filtrov. Glede tehnološkega sklada: zaledje uporablja Flask in MongoDB/GridFS namesto prvotno predvidenih PostgreSQL/Redis in FAISS (gradniki indeksa FAISS obstajajo, a živa poizvedba pregleduje vektorje v bazi), DINOv2 ni vključen, zamisel metričnega učenja pa je uresničena z vložitvijo ArcFace iz razdelka 6. Izdelek prinaša bolj dovršeno in povezano celoto

(uporabniška izkušnja, podprta z zgodbo in animiranimi prehodi med interaktivnimi deli), močnejši klasifikator od predlaganega (doučeni CLIP-ViT namesto ResNeta) ter štiri modele z resnično zanko učenje–izvoz–ovrednotenje.

Kaj je odkrilo merjenje. Več napak, ki jih pregled kode ni razkril, se je pokazalo šele ob kvantitativnem preverjanju filtrov na resnični zbirki in ob vizualnem pregledu rezultatov. Filter smeri črt je sploščen histogram (ρ, θ) bral po napačni osi in je tako razvrščal po legi črt v sliki namesto po njihovi usmerjenosti (84 % zbirke je bilo »poševne«, nič »navpične«; po popravku in rangirani obravnavi vsaka smer vrne tretjino zbirke). Filter telesnih drž je vrednost gruče -1 (»nerazvrščeno«) uporabil kot indeks in je zato vsako nerazvrščeno držo uvrstil med »dvignjene roke«. Pravila so brala tudi sklepe, ki jih model sploh ni videl: MediaPipe za vsako sliko vrne vseh 33 točk okostja, tudi kadar je naslikan le doprsni portret – položaje bokov, kolen in gležnjev tedaj oceni pod robom slike in jih označi z nizko vidnostjo (mediana vidnosti gležnjev je 0,05). Pravila o nogah so torej sklepala iz ugibanih koordinat. Kot glave je obdelala funkcija, ki je enoto ugibala in vrednosti do 2π obravnavala kot radiane, kar je napačno razvrstilo prav čelne portrete. Nazadnje je združeni indeks `index.json` ob ponovnem izračunu posamezne značilke zastarel, ne da bi na to kaj opozoril, in uporabniški vmesnik je prikazoval podatke, ki na disku niso več obstajali; strežnik ga zdaj ob zaznani zastarelosti samodejno obnovi. Te napake navajamo, ker opozarjajo na splošnejše spoznanje: filtri, ki navzven delujejo pravilno, lahko strežejo neveljavne podatke vse dotlej, dokler se rezultati ne preverijo na ravni posameznih slik.

Omejitve. Živa poizvedba pregleduje predpomnjeno matriko NumPy, zato bi bilo treba pri bistveno večjih zbirkah čas iskanja ponovno izmeriti (gradniki indeksa FAISS so pripravljeni). Rezultata F3 in F4 sta zgolj interaktivna približka formalnih mer ustvarjalnosti in vpliva. Prilagojeni vložitvi sta bili ovrednoteni na vzorcu 2000 slik, ne na celotni testni množici. Doučeni CLIP in vložitev ArcFace sta v aplikaciji privzeta in ovrednotena na izločenih množicah, koliko je zamenjava izboljšala iskanje v sami aplikaciji, pa še nismo izmerili. Glava za oceno letnice je najzanesljivejša v podatkovno bogatem 19. in 20. stoletju, pri starejših delih njena napaka občutno naraste, zato vmesnik vsako ocenjeno letnico označi kot negotovo. Za držo portretiranca in rok poročamo izmerjeno pokritost in vizualno pregledano smer (razdelek 7), ki pa temeljita na vzorcu sto slik, ne na formalno označeni množici. Namestitveni paket namizne izdaje je omejen z velikostjo artefaktov: vključuje glavo za oceno letnice (1,2 MB), ne pa doučenega modela CLIP (581 MB) in vložitev ArcFace (330 MB), zato tam iskanje F1 in zemljevid F5 tečeta na izhodiščnem modelu CLIP. Prav tako ne vključuje metapodatkovne tabele WikiArt (38 MB), zato so letnice, slogi in žanri na voljo le prek naučenih modelov, ne iz kataloga.

9. Sklep

Predstavili smo Warden Ship – interaktivno aplikacijo, ki digitalizirano umetniško zbirko spremeni v prostor, po katerem je mogoče krmariti, vso umetno inteligenco pa usmerja v raziskovanje obstoječih, človeško ustvarjenih del. Animirani prehodi povežejo nalaganje arhiva in šest enakovrednih instrumentov (F1–F6) v tematsko dosledno celoto.

Izpolnitev zastavljenih prispevkov. Prvi prispevek, delujoča aplikacija kot povezovalni sloj, je izpolnjen: šest funkcionalnosti, predstavljenih v razdelku 4, je zgrajenih in dosegljivih. Drugi, celovito ovrednotenje klasifikatorja, je izpolnjen s prehodom obeh učenih različic čez celotno izloženo množico, s primerjavo z modelom brez doučitve in z referenčnimi deli (tabela 4). Tretji, cevovod učenja in izvoza, je opisan v razdelku 5, od priprave podatkov iz zbirke WikiArt prek učenja na gruči FRIDA do samostojnega modela TorchScript, ki ga aplikacija nalaga lokalno. Četrti, prilagoditev dveh modelov in učenje tretjega, je izveden v razdelku 6 in predstavljen v tabeli 5. Peti, primerjava načrtovanega z izvedenim, je izpeljan v razdelku 8.

Odgovor na raziskovalni vprašnji. Uvod je zastavil dve empirični vprašanji: kako točni so modeli aplikacije na neodvisni testni množici in koliko je vnaprej naučene modele mogoče izboljšati s prilagoditvijo umetniški domeni. Točnost je izmerjena, vse klasifikacijske modele smo ovrednotili na celotni izločeni množici, testni rezultati pa se ujemajo z validacijskimi in presegajo referenčna dela. Prispevek prilagoditve je občuten povsod, kjer je izhodišče sploh merljivo.

Modele v ozadju naštetih funkcionalnosti smo neodvisno ovrednotili na 12.680 izločenih testnih slikah: doučena različica ViT-L/336 doseže 77,0 % pri slogu, 86,3 % pri žanru in 97,3 % pri avtorju ter s tem za 51, 29 oziroma 41 odstotnih točk preseže CLIP brez doučitve; testna točnost se tesno ujema z validacijsko, kar potrjuje dobro posploševanje. Tri sestavine smo nato prilagodili umetniški domeni oziroma naučili na novo in prispevek izmerili: kontrastno doučeni CLIP dvigne točnost brez doučitve pri slogu na 55,3 % in pri žanru na 79,8 %, metrična vložitev ArcFace izboljša natančnost@1 pri slogu z 41,6 % na 61,0 %, regresijska glava nad vložitvami CLIP pa letnico nastanka oceni s povprečno absolutno napako 31 let ob naivni osnovi 73 let. Nadaljnje delo obsega merjenje,

koliko prilagojeni vložitvi izboljšata iskanje v sami aplikaciji, vklop indeksa FAISS za velike zbirke, morebitno izvedbo polnih omrežij ustvarjalnosti in vplivov ter razširitev prepoznav avtorja prek sedanjih 25 razredov s postopnim oženjem kroga kandidatov: napovedani slog in žanr ob metapodatkih zbirke določita, kateri avtorji so sploh verjetni, med preostalimi kandidati pa razsodi posebej naučena glava za avtorja.

ZAHVALA. Zahvaljujem se mentorici in somentorju za usmeritve ter sošolcem iz skupinskega projekta pri predmetu Osnove oblikovanja, v okviru katerega je nastal prvi delni prototip aplikacije Warden Ship.

Literatura

1. WikiArt (2024) WikiArt – visual art encyclopedia (<https://www.wikiart.org/>). Dostopano: 28. 6. 2026.
2. Deng J, Guo J, Xue N, Zafeiriou S (2019) ArcFace: Additive angular margin loss for deep face recognition in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. pp. 4690–4699.
3. Manovich L (2015) Data science and digital art history. *International Journal for Digital Art History* (1).
4. Castellano G, Vessio G (2021) Deep learning approaches to pattern extraction and recognition in paintings and drawings: An overview. *Neural Computing and Applications* 33(19):12263–12282.
5. Saleh B, Elgammal A (2016) Large-scale classification of fine-art paintings: Learning the right metric on the right feature. *International Journal for Digital Art History* (2).
6. Elgammal A, Liu B, Kim D, Elhoseiny M, Mazzone M (2018) The shape of art history in the eyes of the machine. *Proceedings of the AAAI Conference on Artificial Intelligence* 32(1).
7. Seguin B, Striolo C, di Lenardo I, Kaplan F (2016) Visual link retrieval in a database of paintings in *Computer Vision – ECCV 2016 Workshops*. (Springer), pp. 753–767.
8. Saleh B, Abe K, Arora RS, Elgammal A (2016) Toward automated discovery of artistic influence. *Multimedia Tools and Applications* 75:3565–3591.
9. Elgammal A, Saleh B (2015) Quantifying creativity in art networks in *Proceedings of the Sixth International Conference on Computational Creativity (ICCC)*. pp. 39–46.
10. Stork DG (2024) Computer vision, machine learning, and artificial intelligence in the study of fine-art paintings and drawings. *Communications of the ACM* 67(5):68–76.
11. Radford A et al. (2021) Learning transferable visual models from natural language supervision in *Proceedings of the 38th International Conference on Machine Learning (ICML)*, PMLR. Vol. 139, pp. 8748–8763.
12. Oquab M et al. (2024) DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research (TMLR)*.
13. Jenič J, et al. (2024) Sistem za interaktivno pregledovanje slikarske zbirke in Zbornik štiriindvajsete mednarodne multi-konference Informacijska družba (IS).
14. Muzyka O (2024) Pirate Ship (<https://sketchfab.com/3d-models/pirate-ship-fe0ea2cee119476fb1a7524d5ff380dc>). 3D model, Sketchfab, licenca CC BY 4.0. Dostopano: 13. 8. 2026.
15. Tawsif OF (2024) Fantasy_Island (<https://sketchfab.com/3d-models/fantasy-island-88765d3c5db349e59c39cf9f592eba17>). 3D model, Sketchfab, licenca CC BY 4.0. Dostopano: 13. 8. 2026.
16. Aartee (2024) Stylized telescope (<https://sketchfab.com/3d-models/stylized-telescope-f6cb6b9adfcc4814881e6e6b23382288>). 3D model, Sketchfab, licenca CC BY 4.0. Dostopano: 13. 8. 2026.
17. Eddx1108 (2024) Old Canon 3 (<https://sketchfab.com/3d-models/old-canon-3-2c08d45d3bae49ca9cbc091f9106ca1f>). 3D model, Sketchfab, licenca CC BY 4.0. Dostopano: 13. 8. 2026.
18. Meta Open Source (2024) React – the library for web and native user interfaces (<https://react.dev/>). Dostopano: 28. 6. 2026.
19. Three.js authors (2024) Three.js – javascript 3d library (<https://threejs.org/>). Dostopano: 28. 6. 2026.
20. Poimandres (2024) React Three Fiber documentation (<https://docs.pmnd.rs/react-three-fiber>). Dostopano: 28. 6. 2026.
21. OpenJS Foundation (2024) Electron – build cross-platform desktop apps (<https://www.electronjs.org/>). Dostopano: 28. 6. 2026.
22. Pallets (2024) Flask documentation (<https://flask.palletsprojects.com/>). Dostopano: 28. 6. 2026.
23. MongoDB (2024) GridFS documentation (<https://www.mongodb.com/docs/manual/core/gridfs/>). Dostopano: 28. 6. 2026.
24. Wolf T et al. (2020) Transformers: State-of-the-art natural language processing in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. pp. 38–45.
25. Johnson J, Douze M, Jégou H (2021) Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data* 7(3):535–547.
26. Lugaresi C et al. (2019) MediaPipe: A framework for building perception pipelines. *arXiv preprint arXiv:1906.08172*.
27. Dosovitskiy A et al. (2021) An image is worth 16x16 words: Transformers for image recognition at scale in *International Conference on Learning Representations (ICLR)*.
28. Wightman R (2019) PyTorch image models (timm) (<https://github.com/huggingface/pytorch-image-models>). Dostopano: 28. 6. 2026.
29. Paszke A et al. (2019) PyTorch: An imperative style, high-performance deep learning library in *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 32.

Priloge

A. Zaslonske slike vmesnika

Priloga zbira zaslonske slike vseh prizorov aplikacije v veliki obliki. Posnete so v delujoči aplikaciji z naloženim preizkusnim arhivom 100 slik iz zbirke WikiArt, pri čemer so bili vsi štirje cevovodi (F1, F2, F5 in F6) že izračunani. Polovica slik je naloženih brez pravega imena, zato jih klasifikator F2 razvrsti sam.



Slika 1. Paluba ladje – domači zaslon. Tridimenzionalna ladja *The Warden* na animiranem oceanu, obkrožena s podobami, generiranimi z umetno inteligenco, ki jim ladja simbolno kljubuje. Napis pove, koliko slik je v naloženem arhivu; vrata kabine vodijo v sobo s skrinjo, tipka C pa sproži samodejni animirani ogled celotne aplikacije.




Slika 2. Soba s skrinjo. Klik na skrinjo odpre ladijsko konzolo: uporabnik lahko naloži nov arhiv ZIP ali izbere zbirko, ki je že shranjena v MongoDB (izbrana zbirka je izpisana v levem spodnjem kotu). Arhiv se razširi v brskalniku, slike pa se v paketih pošljejo zaledju; po nalaganju lahko uporabnik takoj sproži cevovode F1, F2, F5 in F6, njihov napredek pa spremlja vrstica na vrhu zaslona.



Slika 3. Otok s teleskopom. Zadnja postaja animiranega toka; pogled skozi teleskop odpre semantično iskanje *Star Atlas*.



Slika 4. Ladijski hodnik. Razdelilnik z vrati do funkcionalnosti F2–F6; vsak instrument je dosegljiv enako neposredno kot iskanje.




Slika 5. F1 – Star Atlas: semantično iskanje. Poizvedba v naravnem jeziku (»ocean sunset«) zbirko preoblikuje v ozvezdje okrog osrednje besede; oddaljenost od središča izraža rang ujemanja (najboljši zadetek tik ob besedi, najšibkejši na obodu), najustreznejše umetnine so tudi najsvetlejše in največje, lebdenje nad zvezdo pa pokaže predogled umetnine s stopnjo ujemanja. Značke ob robu povedo, koliko slik sestavlja ozvezdje in kolikšno je najboljšo ujemanje; barvno temo neba uporabnik izbere sam.




Slika 6. F2 – Logbook: hkratna klasifikacija sloga, žanra in avtorja. Odprt ladijski dnevnik kaže po štiri umetnine na razprtje, pergamentne plošče na steni kabine pa za izbrano sliko izpišejo napovedani slog, žanr in avtorja. Za sliko na posnetku model napove visoko renesanso in religiozno slikarstvo, avtorja pa označi kot neznanega, saj njegovo zaupanje ne doseže praga za nobenega od 25 slikarjev.



Slika 7. F3 – karta ustvarjalnosti. Vsaka umetnina nastopi kot ladjica na stenski pomorski karti; višina in sij izražata oceno ustvarjalnosti, svetlobna črta pa njen trend skozi čas. Značka v levem zgornjem kotu odkrito pove, da je bila letnica pri polovici slik ocenjena z modelom in ne najdena v metapodatkih.



Slika 8. F4 – karta vplivov. Ista karta v drugem načinu izriše časovno usmerjene povezave med vizualno sorodnimi deli; klik na ladjico ohrani samo njeno pot, ponovni klik pa odpre umetnino.



Slika 9. F5 – Chart Table: zemljevid zgodovine umetnosti. Umetnine so razporejene po projekciji vložitev CLIP in po letnici nastanka (vodoravno), obrisi pa označujejo gručo slogovno sorodnih del. Ocenjene letnice so posebej obarvane; dela, ki jim letnice ni bilo mogoče razrešiti, se prikažejo v ločenem pasu »nedatirano« in ne dobijo izmišljene letnice.



Slika 10. F6 – kapitanova kajuta: filtri po vizualnih lastnostih. Vsak filter je predmet v prostoru: globus izbira poreklo, deska z barvili barvo, lesena lutka drži rok, izrezljana glava pogled portretiranca, deska z vrvicami pa značaj črt. Na sliki sta vklopljeni barvili *modra* in *rumena*: ker se barvila sestavljajo s konjunkcijo, ostanejo dela, ki nosijo obe družini – zbirka se s 100 zoži na 40 in nato na 20 del –, ladijski pladenj ob dnu zaslona pa jih sproti izrisuje. Ploščice brez zadetkov v naloženi zbirki so zatemnjene s prikazanim številom.

B. Razredi modelov

Slog (27 razredov, glava F2). Abstract Expressionism, Action Painting, Analytical Cubism, Art Nouveau-Modern Art, Baroque, Color Field Painting, Contemporary Realism, Cubism, Early Renaissance, Expressionism, Fauvism, High Renaissance, Impressionism, Mannerism-Late Renaissance, Minimalism, New Realism, Northern Renaissance, Pointillism, Pop Art, Post Impressionism, Primitivism-Naive Art, Realism, Rococo, Romanticism, Symbolism, Synthetic Cubism, Ukiyo-e.


Žanr (10 razredov, glava F2). Abstract Painting, Cityscape, Genre Painting, Illustration, Landscape, Nude Painting, Portrait, Religious Painting, Sketch and Study, Still Life.

Avtor (25 razredov, glava F2). Ivan Aivazovsky, Zdzislaw Beksinski, Eugene Boudin, Paul Cézanne, Camille Corot, Bela Czobel, Gustave Doré, Paul Gauguin, Hryhorii Havrylenko, Childe Hassam, Scheiber Hugó, Raphael Kirchner, Pyotr Konchalovsky, Alfred Freddy Krupa, Boris Kustodiev, Henri Matisse, Camille Pissarro, Giovanni Battista Piranesi, Ilya Repin, Peter Paul Rubens, John Singer Sargent, Martiros Sarian, Iván Shishkin, Theophile Steinlen, Roger Weik. Gre za 25 najpogostejše zastopanih slikarjev v učni množici; slike vseh preostalih avtorjev glava razvrsti kot *neznane avtorja*, kadar zaupanje ne doseže praga.


Kanali vizualnih lastnosti (F6). Drža rok (tri medsebojno izključujoče oznake – dvignjene, razprte, spuščene – iz 33 točk okostja MediaPipe ob upoštevanju vidnosti sklepov), barve (šest barvnih družin, ki si razdelijo barvni krog – rdeča, oranžna, rumena, zelena, modra, vijolična –, delo pa je uvrščeno pod vsako družino, ki pokriva vsaj 12 % platna, ter tretjinska pasova nasičenosti in svetlosti, ki pripeti družini le jo opredelita), značaj črt (Houghova transformacija: gostota ter najbolj navpična, poševna oziroma vodoravna tretjina zbirke) in pogled portretiranca (RetinaFace, pet sektorjev od levega profila do desnega glede na zasuk glave). Filter porekla narodnosti avtorja iz metapodatkov WikiArt preslika v celino.

C. Arhitektura aplikacije in modelov

Priloga združuje oba pregledna diagrama: prvi pokaže, kateri model poganja katero funkcionalnost, drugi pa notranjo zgradbo modelov, ki smo jih naučili ali prilagodili umetniški domeni.



Slika 11. Arhitektura aplikacije *Warden Ship*: prizori čelnega dela, poti zaledja Flask, modeli in shramba. Vsak stolpec povezuje eno funkcionalnost z modeli, ki jo poganjajo; zvezdica označuje modele, naučene ali prilagojene v tem delu, sivi okvirji pa vnaprej naučene in zamrznjene sestavine.



Slika 12. Zgradba štirih modelov, ki smo jih v tem delu naučili ali prilagodili umetniški domeni: (a) klasifikator F2 z eno osnovno mrežo in tremi izhodnimi glavami, (b) kontrastna doučitev modela CLIP na parih slika–opis, (c) metrična vložitev z izgubo ArcFace in (d) glava za oceno letnice nastanka kot ordinalna regresija čez desetletne razrede. Ovrednotenje vseh štirih je v razdelku 7.